Part A

思路分析

关键点在于cache结构体的设计与算法的实现。此外就是初始化cache,模式选择和输入输出读取。

具体实现

全局变量

```
// 缓存参数
int s, E, b, S; // s: 组索引位数, E: 每组的行数, b: 块偏移位数, S: 组数 char file[100]; // 存储内存访问轨迹的文件名

// 缓存统计数据
int hit_count = 0, miss_count = 0, eviction_count = 0;

// 全局计数器,用于缓存替换策略
int count = -1;
```

输入输出

对于输入输出和模式选择,直接参考PPT中给出的 getopt 和 fscanf 操作即可,根据PPT上的实现能够处理好操作的读取。

cache设计

首先知道应该是一个二维数组,其中具体元素需要包括 tag 即标识位,此外,为了实现所需算法,还要一个变量用来记录时间。

```
struct Cache
{
   int tag;
   int time;
} **cache;
```

此外要对cache进行初始化,为防止segmentation fault,需要逐行开辟空间。又由于C中不能直接给结构体变量赋初始值,所以在初始化时还需要赋给初始值。

对于tag,需要初始化为1个负数,来标志空行,同时防止和真实tag相冲突。

对于 time, 可以任意赋给一个相同初始值。

算法实现

首先,有四种模式,对应四种访问操作。

- 1. I 可以直接跳过。
- 2. 对于 L 和 S , 都是直接访问一次即可。
- 3. 对于M模式,在访问第一次之后,可以知道马上的第二次一定会命中,就不用再次访问,直接count加1就可以。

对干访问操作:

首先需要拿到数据的tag和set,利用位移操作实现。此外,增加了三个辅助变量,来实现判断,分别是标志第一个空行位置的empty_set,找到目前时间最大值以及对应下标的max和max_index.

```
unsigned tag = addr >> (b + s); unsigned set = addr << (64 - b - s) >> (64 - s);//清除无效位,得到s。 int empty_set = -1; int max = 1 << 31;//为保证正确更新,初始化为最小负数。 int max_index = 0;
```

此后就是实现算法。

为了实现,初始化了一个全局变量 count ,每次循环的时候-1,每次进行行访问时,将其赋值给对应的 time 。相比于对所有cache的计数器加1,这能够用较小代价保证时间的正确更新。(最新访问的永远 是数值最小的,访问时间越久远对应数值越大)。

在最后的循环中,同时进行匹配,空行判断,time最大值行判断。

如果匹配成功直接hit+1然后return。

如果匹配失败,空行判断成功,miss+1,然后替换空行。

如果都失败, miss+1, 替换+1, 然后替换对应的行。

最后就结束了。

Part B

32×32

直接利用ppt中的分块技术。

每次访问会读到同一行的8个整数,8行可以充满整个cache。

在转置时,按照8*8的块,除对角线上的,别的地方都能很好地解决。

处理对角线时,可以通过局部变量把读到的A的一整行存起来,再赋值给B实现。

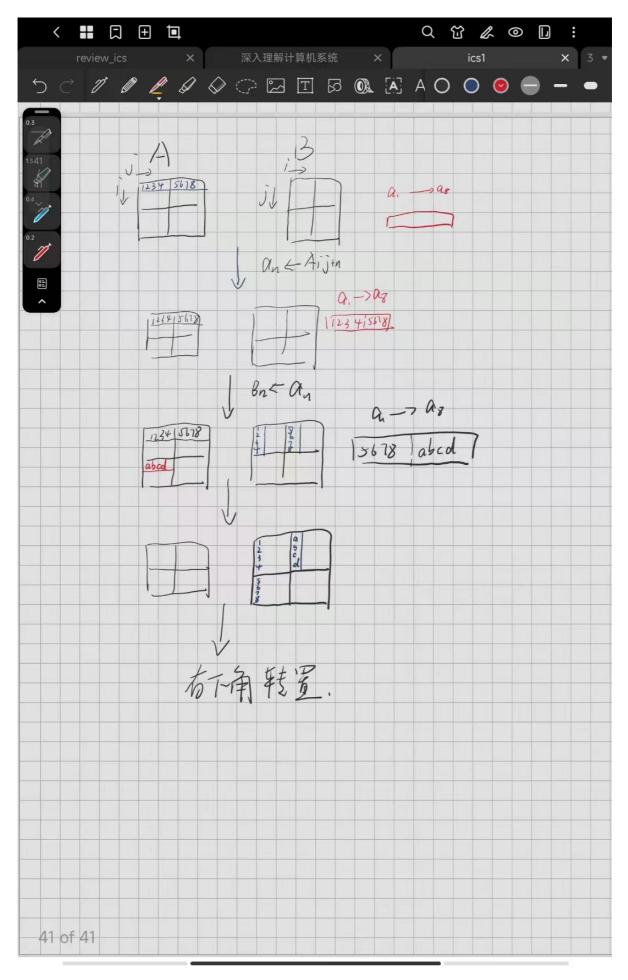
这样这个部分就能满分了。

64×64

直接按照上一题的8*8会由于冲突导致四千多次miss,因为这个时候转置对应的8*8块之间会发生大量冲突。

为了解决这个冲突问题,就需要一些操作,就是在大的分块的基础上再进行小的分块。分成4个4*4的。

具体过程如图:



也就是说,先把A左上角和右上角给局部变量,然后在B的左上角和右上角分别放下转置的A矩阵左上角和右上角。

此时B的左上角已经完成转置。

然后把B的右上角和A的左下角给局部变量。

分别对应B的左下角和右上角。

此时只剩右下角。

右下角直接可以用分块实现。

61×67

这个地方cache对应太难算了,想了很久没想明白具体对应关系。

最后就只能直接用16*16的最简单的分块了,刚好可以过。